

Laporan Akhir Proyek Data Warehouse

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-D
Ketua	Devita Nur Aisyah (24031554125)
Anggota 1	Aisyah Imani Khoirunnisa (24031554020)
Anggota 2	Elvira Rizki Berliananda Pamudji (24031554062)
URL Github	URL Github

Informasi Umum Proyek

Judul	Implementasi Data Warehouse untuk Analisis Populasi Kendaraan Listrik di Washington State
Topik	Transportasi
Revisi?	Ya / Tidak

Deskripsi Rumusan masalah	Peningkatan penggunaan kendaraan listrik (Electric Vehicle/EV) di Washington State menunjukkan semakin besarnya peran transportasi ramah lingkungan dalam mengurangi emisi dan mendukung perkembangan teknologi. Namun, pertumbuhan populasi kendaraan listrik yang semakin pesat menyebabkan data kendaraan terus bertambah dan menjadi lebih kompleks, terutama untuk memantau tren pertumbuhan, persebaran wilayah, serta jenis kendaraan yang digunakan di Washington State. Kondisi ini membuat proses pengelolaan dan analisis data menjadi kurang efektif apabila masih menggunakan sistem yang belum terintegrasi, sehingga informasi mengenai tren pertumbuhan dan distribusi kendaraan listrik sulit dianalisis secara cepat dan menyeluruh. Permasalahan tersebut diperlukan sistem yang mampu mengintegrasikan, menyimpan, dan menganalisis data dalam jumlah besar secara terstruktur. Oleh karena itu, proyek ini membangun Data Warehouse menggunakan PostgreSQL dan Atoti untuk mendukung proses ETL, analisis OLAP, dan visualisasi data agar informasi populasi kendaraan listrik di Washington State dapat dianalisis lebih cepat dan mudah dipahami.
Target insight yang ingin dicapai	Melalui proses Data Staging, Electric Vehicle Population Data akan dibersihkan, diseragamkan, dan diintegrasikan agar siap digunakan untuk analisis. Selanjutnya, pada tahap Data Presentation menggunakan mekanisme CUBE query, insight yang ingin diperoleh adalah tren pertumbuhan populasi kendaraan listrik setiap tahun, persebaran kendaraan listrik berdasarkan county atau kota di Washington State, merk dan model kendaraan listrik yang paling banyak digunakan, perbandingan jenis kendaraan listrik seperti Battery Electric Vehicle (BEV) dan Plug-in Hybrid Electric Vehicle (PHEV), serta analisis rata-rata electric range kendaraan. Dengan analisis multidimensi tersebut, data dapat memberikan informasi yang lebih mudah dipahami untuk melihat pola perkembangan kendaraan listrik berdasarkan waktu, lokasi, dan karakteristik kendaraan.
Referensi penelitian	https://doi.org/10.1186/s42162-025-00615-4 https://doi.org/10.1038/s41597-024-02942-9 https://doi.org/10.1109/ACCESS.2023.3240102

Informasi Detil Dataset

Sumber dataset	https://catalog.data.gov/dataset/electric-vehicle-population-data
Deskripsi umum dataset / datadump	<i>Dataset Electric Vehicle Population Data merupakan dataset yang berisi informasi mengenai populasi kendaraan listrik yang terdaftar di wilayah Washington, Amerika Serikat. Dataset ini mencakup berbagai informasi seperti jenis kendaraan listrik, merek kendaraan, model, tahun produksi, jenis bahan bakar listrik, lokasi registrasi, hingga estimasi jarak tempuh kendaraan listrik. Dat ini disediakan oleh pemerintah melalui portal Data.gov dan dapat digunakan untuk analisis perkembangan penggunaan kendaraan listrik, segmentasi kendaraan maupun penelitian terkait transportasi ramah lingkungan</i>
Aspek khusus dari dataset	<i>Dataset terdiri dari 280.833 baris dan 16 atribut dengan tipe data kategorik dan numerik yang memuat informasi kendaraan listrik. Dataset memiliki tingkat sparsity yang sangat rendah, yaitu sebesar 0,02% dengan total 795 missing value, sehingga data terbilang lengkap dan layak digunakan dalam proses analisis. Distribusi pada atribut Electric Vehicle Type menunjukkan kondisi imbalanced, di mana tipe Battery Electric Vehicle (BEV) mendominasi sebanyak 225.124 data dibandingkan Plug-in Hybrid Electric Vehicle (PHEV) sebanyak 55.709 data dengan rasio sekitar 4,04:1. Kondisi ini menunjukkan bahwa mayoritas kendaraan listrik yang terdaftar di Washington State merupakan kendaraan listrik penuh (BEV). Selain itu, hasil pemeriksaan menunjukkan tidak terdapat data duplikat pada dataset sehingga kualitas data relatif baik untuk digunakan dalam pembangunan data warehouse dan analisis OLAP.</i>

Hasil Pengerjaan Data Staging

Tahap ekstraksi	<i>Pada tahap ekstraksi, dataset Electric Vehicle Population Data diekstraksi dari file CSV menggunakan library Pandas. Dataset yang digunakan berisi 280.833 record dan 16 atribut yang mencakup informasi kendaraan listrik di Washington State, seperti lokasi kendaraan, tahun model, merek, tipe kendaraan listrik, jangkauan listrik (electric range), serta utilitas penyedia listrik. Setelah data berhasil dimuat, dilakukan pemeriksaan struktur data untuk memahami karakteristik dataset, tipe data setiap atribut, serta statistik deskriptif dari atribut numerik. Selanjutnya dilakukan identifikasi kualitas data dengan memeriksa keberadaan missing value pada setiap atribut. Hasil pemeriksaan menunjukkan bahwa beberapa kolom masih memiliki data yang tidak lengkap, seperti County, City, Postal Code, Electric Range, Electric Utility, dan 2020 Census Tract yang masing-masing memiliki 12 nilai kosong, Vehicle Location sebanyak 20 nilai kosong, serta Legislative District sebanyak 703 nilai kosong.</i> <i>Secara keseluruhan terdapat 795 missing value pada dataset dengan tingkat sparsity sebesar 0,0177%, yang menunjukkan bahwa proporsi data yang hilang relatif sangat kecil dibandingkan total data yang tersedia. Selain itu, hasil eksplorasi awal menunjukkan bahwa tipe kendaraan listrik Battery Electric Vehicle (BEV) mendominasi dataset dengan jumlah 225.124 kendaraan, sedangkan Plug-in Hybrid Electric Vehicle (PHEV) berjumlah 55.709 kendaraan. Perbandingan keduanya mencapai 4,04 : 1, yang mengindikasikan bahwa penggunaan kendaraan listrik berbasis baterai penuh jauh lebih banyak dibandingkan kendaraan listrik hibrida plug-in di Washington State. Informasi hasil ekstraksi ini menjadi dasar untuk proses pembersihan dan transformasi data pada tahap berikutnya agar data yang dimuat ke dalam data warehouse memiliki kualitas yang lebih baik dan siap digunakan untuk analisis.</i>
Tahap transformasi	<i>Pada tahap transformasi, dilakukan pembersihan data dengan menangani missing value pada setiap atribut. Missing value pada atribut numerik diisi menggunakan median karena lebih tahan terhadap pengaruh outlier dan mampu merepresentasikan</i>


	nilai tengah data dengan baik, sedangkan atribut kategorikal diisi menggunakan modus karena menunjukkan kategori yang paling sering muncul. Dipilih metode imputasi dibandingkan menghapus data, agar seluruh data tetap dimanfaatkan dalam analisis. Penghapusan data yang mengandung missing value bisa mengurangi jumlah data, menghilangkan informasi yang masih relevan pada atribut lain. Selain itu, dilakukan standarisasi nama kolom dengan mengubah seluruh nama atribut menjadi huruf kecil, mengganti spasi dengan underscore (_), dan menyederhanakan nama kolom <code>clean_alternative_fuel_vehicle_(cafve)eligibility</code> menjadi <code>cafve_eligibility</code> agar mudah digunakan dalam proses pengolahan. Setelah data dibersihkan, dilakukan konversi tipe data pada atribut <code>model_year</code> dan <code>electric_range</code> menjadi integer untuk memastikan kesesuaian tipe data dengan kebutuhan analisis. Selanjutnya, data diorganisasikan ke dalam beberapa tabel dimensi yang terdiri dari <code>dim_time</code>, <code>dim_location</code>, <code>dim_vehicle</code>, dan <code>dim_utility</code>. Pembentukan tabel dimensi bertujuan untuk mengurangi redundansi data, meningkatkan efisiensi penyimpanan, serta membantu analisis multidimensi dan star schema. Pada tahap berikutnya, setiap label dimensi diberikan primary key berupa surrogate key yang dibuat secara otomatis, yaitu <code>time_id</code>, <code>location_id</code>, <code>vehicle_id</code>, dan <code>utility_id</code>. Seluruh tabel dimensi kemudian diintegrasikan ke dalam fact table (<code>fact_ev_population</code>) melalui proses penggabungan. Fact table yang dihasilkan menyimpan foreign key dari masing-masing dimensi serta measure utama, yaitu <code>electric_range</code> dan <code>vehicle_count</code>, sehingga membentuk star schema untuk proses OLAP dan analisis lebih lanjut.
Tahap load	Pada tahap load, data hasil transformasi dimuat ke dalam database PostgreSQL menggunakan library <code>SQLAlchemy</code> dan <code>psycopg2</code> pada Python. Tabel dimensi yang terdiri dari <code>dim_time</code>, <code>dim_location</code>, <code>dim_vehicle</code> dan <code>dim_utility</code> serta tabel fakta <code>fact_ev_population</code> berhasil disimpan ke dalam data warehouse dengan struktur <code>schema</code>. Database yang dihasilkan memiliki ukuran sekitar 31 MB setelah seluruh tabel, relasi, dan materialized view dimuat ke PostgreSQL. Selain itu, teknologi PostgreSQL yang digunakan dalam proyek ini meliputi primary key foreign key, materialized view, serta query agregasi SQL untuk mendukung proses analisis multidimensi ada data populasi kendaraan listrik. Performa benchmarking dilakukan menggunakan perintah <code>EXPLAIN ANALYZE</code> pada PostgreSQL dengan membandingkan waktu eksekusi query agregasi sebelum dan sesudah penggunaan materialized view. Hasil pengujian menunjukkan bahwa waktu eksekusi query menjadi lebih cepat setelah menggunakan materialized view dibanding melakukan akses langsung pada tabel fakta dan tabel dimensi. Hasil tersebut menunjukkan bahwa optimasi yang diterapkan mampu meningkatkan efisiensi proses OLAP sehingga analisis populasi kendaraan listrik dapat dilakukan dengan lebih cepat dan efektif menggunakan PostgreSQL dan Atoti.

Hasil Pengerjaan Data Presentation

Subject focus	Berdasarkan hasil OLAP yang diperoleh, proses analisis difokuskan pada populasi kendaraan listrik di Washington State dari berbagai sudut pandang dimensi yang telah dibangun pada data warehouse. Analisis pertama mengangkat distribusi kendaraan listrik berdasarkan county, yang menunjukkan bahwa jumlah kendaraan listrik tersebar di 250 county dengan beberapa wilayah memiliki populasi yang jauh lebih tinggi dibandingkan wilayah lainnya. Analisis kedua berfokus pada distribusi kendaraan listrik berdasarkan kota untuk mengetahui kota-kota dengan tingkat adopsi kendaraan listrik tertinggi di antara 905 kota yang tercatat dalam dataset.
---------------	--

Selanjutnya, analisis dilakukan berdasarkan merek kendaraan untuk mengidentifikasi produsen kendaraan listrik yang paling dominan. Hasil menunjukkan bahwa Tesla menjadi merek dengan populasi kendaraan listrik terbesar, mencapai 114.817 unit, jauh melampaui merek lainnya seperti Chevrolet, Nissan, Ford, dan Toyota. Analisis berikutnya dilakukan pada tingkat model kendaraan, yang bertujuan mengetahui model kendaraan listrik yang paling banyak digunakan oleh masyarakat. Informasi ini dapat memberikan gambaran mengenai preferensi konsumen terhadap tipe kendaraan listrik tertentu.

Selain itu, OLAP juga mengangkat analisis berdasarkan jenis kendaraan listrik (Electric Vehicle Type). Hasil menunjukkan bahwa Battery Electric Vehicle (BEV) mendominasi dengan jumlah 225.124 kendaraan atau sekitar 80% dari total populasi kendaraan listrik, sedangkan Plug-in Hybrid Electric Vehicle (PHEV) berjumlah 55.709 kendaraan. Kondisi ini mengindikasikan bahwa masyarakat lebih banyak menggunakan kendaraan listrik murni dibandingkan kendaraan hybrid plug-in. Analisis terakhir berfokus pada total electric range berdasarkan merek kendaraan. Hasil menunjukkan bahwa Tesla memiliki total electric range tertinggi sebesar 5.840.873 mil, diikuti oleh Chevrolet dan Nissan. Analisis ini memberikan gambaran kontribusi masing-masing merek terhadap kapasitas jangkauan kendaraan listrik yang beredar. Dengan demikian, proses OLAP tidak hanya menampilkan jumlah kendaraan listrik, tetapi juga mampu memberikan wawasan mengenai persebaran wilayah, preferensi merek dan model, dominasi jenis kendaraan listrik, serta karakteristik performa kendaraan berdasarkan electric range.





Gambar 1. Star Schema

Star schema


Struktur star schema pada proyek ini terdiri dari satu tabel fakta yaitu *fact_ev_population* dan empat tabel dimensi yaitu *dim_time*, *dim_location*, *dim_vehicle*, dan *dim_utility*. Tabel *fact_ev_population* digunakan sebagai pusat analisis OLAP karena menyimpan foreign key dari setiap dimensi serta atribut *electric_range* yang digunakan sebagai measure dalam proses analisis. Selain itu, jumlah kendaraan dapat diperoleh melalui proses agregasi (count) pada tabel fakta.

Tabel *dim_time* digunakan sebagai dimensi waktu untuk analisis tren kendaraan listrik berdasarkan tahun. Tabel *dim_location* digunakan sebagai dimensi lokasi untuk analisis persebaran kendaraan listrik berdasarkan county, city, dan state. Tabel *dim_vehicle* digunakan sebagai dimensi kendaraan untuk analisis merek, model, serta jenis kendaraan listrik. Sementara itu, tabel *dim_utility* digunakan sebagai dimensi utilitas listrik untuk melihat distribusi kendaraan berdasarkan penyedia utilitas listrik. Struktur star schema ini mendukung proses OLAP seperti drill-down, roll-up, slicing, dan dicing sehingga analisis multidimensi dapat dilakukan secara lebih


	efisien.
Hasil OLAP	Hasil OLAP berdasarkan dimensi lokasi menunjukkan bahwa county King menjadi wilayah dengan jumlah kendaraan listrik tertinggi, yaitu sekitar 138000 kendaraan. Hal serupa terlihat pada tingkat kota, di mana Seattle menempati posisi pertama sekitar 43000 lebih kendaraan listrik. Hasil tersebut menunjukkan bahwa penggunaan kendaraan listrik cenderung mendominasi pada wilayah perkotaan dan daerah dengan tingkat aktivitas ekonomi yang lebih tinggi dan memiliki infrastruktur pendukung kendaraan listrik. Analisis berdasarkan dimensi kendaraan menunjukkan dominasi yang sangat kuat dari merek Tesla dengan total 114.817 kendaraan. Pada tingkat model, Tesla Model Y menjadi model kendaraan listrik yang paling banyak digunakan. Selain itu, distribusi jenis kendaran listrik menunjukkan bahwa Battery Electric Vehicle (BEV) mendominasi pasar dengan 80.2%, sedangkan Plug-in Hybrid Electric Vehicle (PHEV) hanya sebesar 19.8%. Hasil tersebut menunjukkan bahwa masyarakat lebih memilih kendaraan listrik murni dibandingkan kendaraan hybrid, yang mencerminkan meningkatnya penerimaan terhadap teknologi kendaraan listrik tanpa ketergantungan pada bahan konvensional . Analisis terhadap total electric range juga menunjukkan dominasi Tesla dengan akumulasi jangkauan listrik mencapai 5.840.873. Tingginya total electric range Tesla tidak hanya disebabkan oleh banyaknya jumlah kendaraan yang terdaftar, tetapi juga kendaraan Tesla yang umumnya memiliki kemampuan jangkauan listrik yang kompetitif dibandingkan merek lain. Hasil proses OLAP pada analisis menunjukkan bahwa data warehouse yang dilakukan telah mampu mendukung analisis multidimensi terhadap data kendaraan listrik berdasarkan lokasi, merek, model, jenis kendaraan, dan jangkauan listrik.
Visualisasi OLAP	Berikut merupakan hasil visualisasi yang kami dapatkan:  Gambar 2. Top 10 County dengan Kendaraan Listrik Terbanyak




Gambar 3. Top 10 Kota dengan Kendaraan Listrik Terbanyak




Gambar 4. Top 10 Merek Kendaraan Listrik



Gambar 5. Top 10 Model Kendaraan Listrik



Gambar 6. Distribusi Jenis Kendaraan Listrik



Gambar 7. Top 10 Total Electric Range per Merek